

diabetes_analysis

October 4, 2025

1 Phân tích và tiền xử lý bộ dữ liệu Tiểu Đường (Pima Indians Diabetes)

1.1 1. Định nghĩa vấn đề (Define Problem)

- Mô tả: Bộ dữ liệu Pima Indians Diabetes dùng để dự đoán khả năng mắc bệnh tiểu đường kiểu 2.
- Mục tiêu: Xây dựng pipeline tiền xử lý dữ liệu phục vụ huấn luyện mô hình phân loại biến đầu ra **Outcome**.
- Biến đầu ra (Output): **Outcome** (0: không mắc tiểu đường, 1: mắc tiểu đường)
- Các biến đầu vào (Input Features):
 1. Pregnancies: Số lần mang thai
 2. Glucose: Nồng độ glucose huyết tương sau 2 giờ (mg/dL)
 3. BloodPressure: Huyết áp tâm trương (mm Hg)
 4. SkinThickness: Độ dày nếp gấp da cơ tam đầu (mm)
 5. Insulin: Nồng độ insulin trong huyết thanh (mu U/ml)
 6. BMI: Chỉ số khối cơ thể (kg/m^2)
 7. DiabetesPedigreeFunction: Chỉ số phả hệ tiểu đường (khả năng di truyền)
 8. Age: Tuổi (năm)
- Ghi chú: Một số cột có giá trị 0 là không hợp lệ về mặt sinh học (Glucose, BloodPressure, SkinThickness, Insulin, BMI) và sẽ được xem như giá trị thiếu (missing).

1.2 2. Khai báo thư viện (Load Libraries)

```
[1]: # Load libraries
import os, sys, warnings
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import joblib
from IPython import display

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler, StandardScaler
from sklearn.impute import SimpleImputer

warnings.filterwarnings("ignore")
```

```
%matplotlib inline

plt.rcParams['figure.figsize'] = (12, 6)
plt.rcParams['axes.grid'] = True

print('Libraries loaded.')
```

Libraries loaded.

1.3 3. Nạp dữ liệu (Load Dataset)

```
[2]: # Load dataset
DATA_PATH = 'diabetes.csv'
df_raw = pd.read_csv(DATA_PATH)
df = df_raw.copy()
print(f'+ Shape: {df.shape}')
# Use display.display due to module import
display.display(df.head())
```

+ Shape: (768, 9)

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	\
0	6	148	72	35	0	33.6	
1	1	85	66	29	0	26.6	
2	8	183	64	0	0	23.3	
3	1	89	66	23	94	28.1	
4	0	137	40	35	168	43.1	

	DiabetesPedigreeFunction	Age	Outcome
0	0.627	50	1
1	0.351	31	0
2	0.672	32	1
3	0.167	21	0
4	2.288	33	1

1.4 4. Hiển thị thông tin dữ liệu (Data Overview)

- Kiểm tra kích thước, kiểu dữ liệu, vài dòng đầu/cuối, thông tin tổng quát.
- Kiểm tra giá trị duy nhất của Outcome.

```
[3]: # Data Overview
print(f'+ Shape: {df.shape}')
print('\n+ Dtypes:')
print(df.dtypes)
print('\n+ Head:')
display.display(df.head())
print('\n+ Tail:')
display.display(df.tail())
```

```
print('\n+ Info:')
df.info()
print('\n+ Unique Outcome values:', df['Outcome'].unique())
```

+ Shape: (768, 9)

+ Dtypes:

```
Pregnancies      int64
Glucose           int64
BloodPressure     int64
SkinThickness     int64
Insulin           int64
BMI               float64
DiabetesPedigreeFunction float64
Age               int64
Outcome           int64
dtype: object
```

+ Head:

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	\
0	6	148	72	35	0	33.6	
1	1	85	66	29	0	26.6	
2	8	183	64	0	0	23.3	
3	1	89	66	23	94	28.1	
4	0	137	40	35	168	43.1	

	DiabetesPedigreeFunction	Age	Outcome
0	0.627	50	1
1	0.351	31	0
2	0.672	32	1
3	0.167	21	0
4	2.288	33	1

+ Tail:

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	\
763	10	101	76	48	180	32.9	
764	2	122	70	27	0	36.8	
765	5	121	72	23	112	26.2	
766	1	126	60	0	0	30.1	
767	1	93	70	31	0	30.4	

	DiabetesPedigreeFunction	Age	Outcome
763	0.171	63	0
764	0.340	27	0
765	0.245	30	0
766	0.349	47	1

767 0.315 23 0

+ Info:

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 768 entries, 0 to 767

Data columns (total 9 columns):

#	Column	Non-Null Count	Dtype
0	Pregnancies	768 non-null	int64
1	Glucose	768 non-null	int64
2	BloodPressure	768 non-null	int64
3	SkinThickness	768 non-null	int64
4	Insulin	768 non-null	int64
5	BMI	768 non-null	float64
6	DiabetesPedigreeFunction	768 non-null	float64
7	Age	768 non-null	int64
8	Outcome	768 non-null	int64

dtypes: float64(2), int64(7)

memory usage: 54.1 KB

+ Unique Outcome values: [1 0]

1.5 5. Kiểm tra tính toàn vẹn dữ liệu (Data Integrity Checks)

- Null / NaN
- Duplicates
- Cột có nhiều giá trị 0 bất thường

```
[4]: # Integrity checks
null_counts = df.isnull().sum()
nan_counts = df.isna().sum()
duplicated_n = df.duplicated().sum()
print('+ Null counts:\n', null_counts)
print('\n+ NaN counts:\n', nan_counts)
print(f'\n+ Duplicated rows: {duplicated_n}')
if duplicated_n>0:
    display.display(df[df.duplicated()])

# Columns with zeros possibly invalid
invalid_zero_cols = ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI']
zero_summary = {c: int((df[c]==0).sum()) for c in invalid_zero_cols}
print('\n+ Zero value counts (potential missing):')
for k,v in zero_summary.items():
    print(f' - {k}: {v}')
```

+ Null counts:

Pregnancies	0
Glucose	0

```

BloodPressure      0
SkinThickness      0
Insulin            0
BMI                0
DiabetesPedigreeFunction  0
Age                0
Outcome            0
dtype: int64

+ NaN counts:
  Pregnancies      0
  Glucose          0
  BloodPressure    0
  SkinThickness    0
  Insulin          0
  BMI              0
  DiabetesPedigreeFunction  0
  Age              0
  Outcome          0
dtype: int64

+ Duplicated rows: 0

+ Zero value counts (potential missing):
- Glucose: 5
- BloodPressure: 35
- SkinThickness: 227
- Insulin: 374
- BMI: 11

```

Nhận xét dữ liệu: - Bộ dữ liệu gồm 768 dòng và 9 cột. - Không có giá trị null/NaN thực sự, nhưng nhiều cột sinh học có giá trị 0 bất thường (Glucose, BloodPressure, SkinThickness, Insulin, BMI). - Outcome đã được mã hóa nhị phân (0/1), tỷ lệ lớp có sự mất cân bằng nhẹ. - Một số biến có phân phối lệch (skew) và có thể có ngoại lệ (outlier). - Cần xử lý giá trị 0 bất hợp lệ và chuẩn hóa dữ liệu trước khi huấn luyện mô hình.

1.6 6. Thống kê mô tả (Descriptive Statistics)

- Thống kê cơ bản, skew, kurtosis; nhận xét phạm vi và phân phối sơ bộ.

```

[5]: # Descriptive statistics
desc = df.describe().T
skewness = df.skew().to_frame(name='skew')
kurtosis = df.kurtosis().to_frame(name='kurtosis')
desc_full = desc.join(skewness).join(kurtosis)
display.display(desc_full)

print('\nRange check:')

```

```
for c in df.columns:
    print(f'{c}: min={df[c].min()}, max={df[c].max()}')
```

	count	mean	std	min	25%	\
Pregnancies	768.0	3.845052	3.369578	0.000	1.00000	
Glucose	768.0	120.894531	31.972618	0.000	99.00000	
BloodPressure	768.0	69.105469	19.355807	0.000	62.00000	
SkinThickness	768.0	20.536458	15.952218	0.000	0.00000	
Insulin	768.0	79.799479	115.244002	0.000	0.00000	
BMI	768.0	31.992578	7.884160	0.000	27.30000	
DiabetesPedigreeFunction	768.0	0.471876	0.331329	0.078	0.24375	
Age	768.0	33.240885	11.760232	21.000	24.00000	
Outcome	768.0	0.348958	0.476951	0.000	0.00000	

	50%	75%	max	skew	kurtosis
Pregnancies	3.0000	6.00000	17.00	0.901674	0.159220
Glucose	117.0000	140.25000	199.00	0.173754	0.640780
BloodPressure	72.0000	80.00000	122.00	-1.843608	5.180157
SkinThickness	23.0000	32.00000	99.00	0.109372	-0.520072
Insulin	30.5000	127.25000	846.00	2.272251	7.214260
BMI	32.0000	36.60000	67.10	-0.428982	3.290443
DiabetesPedigreeFunction	0.3725	0.62625	2.42	1.919911	5.594954
Age	29.0000	41.00000	81.00	1.129597	0.643159
Outcome	0.0000	1.00000	1.00	0.635017	-1.600930

Range check:

Pregnancies: min=0, max=17

Glucose: min=0, max=199

BloodPressure: min=0, max=122

SkinThickness: min=0, max=99

Insulin: min=0, max=846

BMI: min=0.0, max=67.1

DiabetesPedigreeFunction: min=0.078, max=2.42

Age: min=21, max=81

Outcome: min=0, max=1

1.7 7. Phân bố Outcome & mất cân bằng lớp (Outcome Distribution)

- Dếm số lượng và tỉ lệ phần trăm mỗi lớp.

```
[6]: # Outcome distribution
counts = df['Outcome'].value_counts().sort_index()
perc = counts / counts.sum() * 100
print('Counts:\n', counts)
print('\nPercent (%):\n', perc.round(2))
fig, ax = plt.subplots()
ax.bar(counts.index.astype(str), counts.values, color=['steelblue', 'tomato'])
```

```

ax.set_xlabel('Outcome')
ax.set_ylabel('Count')
ax.set_title('Outcome Distribution')
for i,v in enumerate(counts.values):
    ax.text(i, v+2, f'{perc.values[i]:.1f}%', ha='center')
plt.show()

```

Counts:

Outcome

0 500

1 268

Name: count, dtype: int64

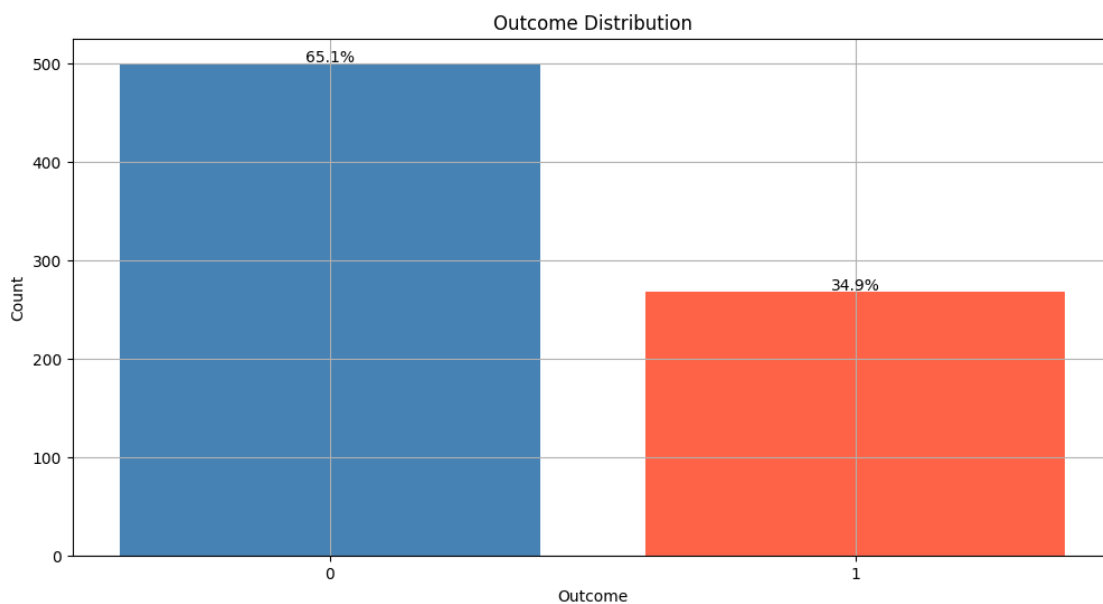
Percent (%):

Outcome

0 65.1

1 34.9

Name: count, dtype: float64



1.8 9. Ma trận tương quan (Correlation Matrix)

- Pearson correlation & heatmap; top thuộc tính tương quan với Outcome.

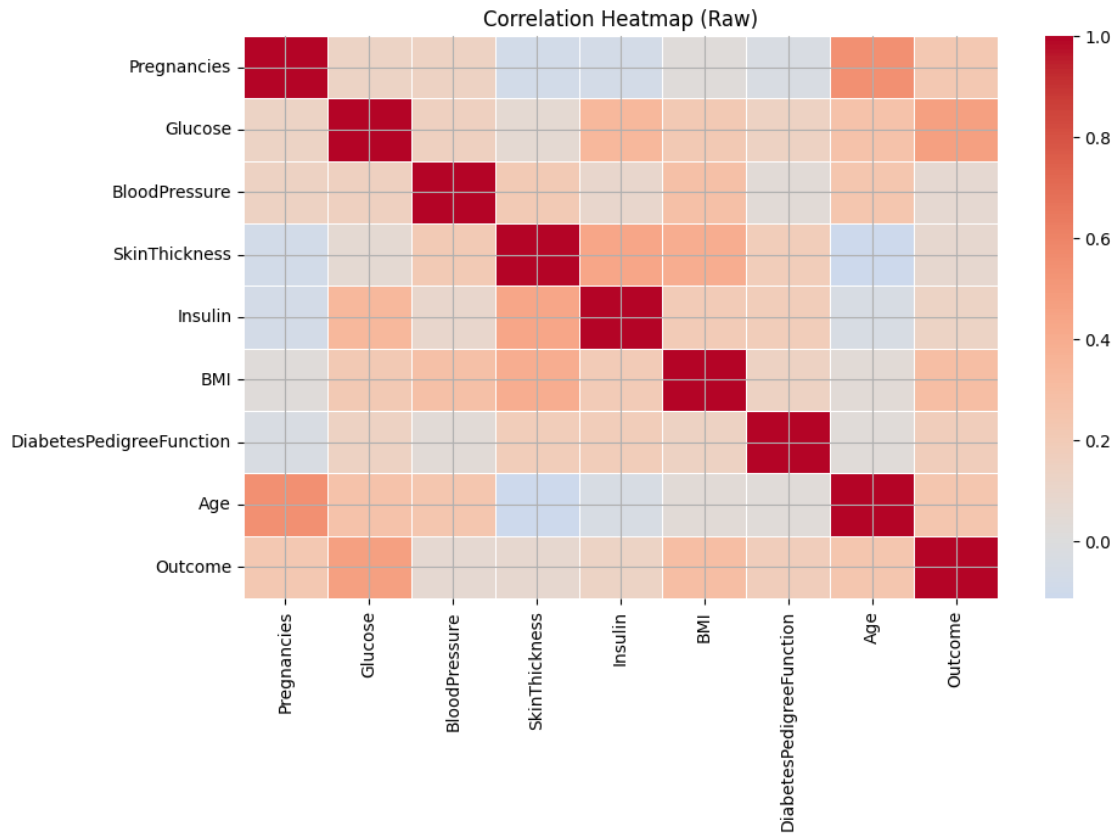
```

[7]: # Correlation matrix
corr = df.corr(method='pearson')
plt.figure(figsize=(10,6))
sns.heatmap(corr, annot=False, cmap='coolwarm', center=0, linewidths=.5)
plt.title('Correlation Heatmap (Raw)')

```

```
plt.show()

outcome_corr = corr['Outcome'].drop('Outcome').abs().
    ↳sort_values(ascending=False)
print('Top correlations (abs) with Outcome:')
print(outcome_corr)
```



```
Top correlations (abs) with Outcome:
Glucose          0.466581
BMI              0.292695
Age              0.238356
Pregnancies      0.221898
DiabetesPedigreeFunction  0.173844
Insulin          0.130548
SkinThickness    0.074752
BloodPressure    0.065068
Name: Outcome, dtype: float64
```


1.9 10. Hiện thị đơn biến (Univariate Plots)

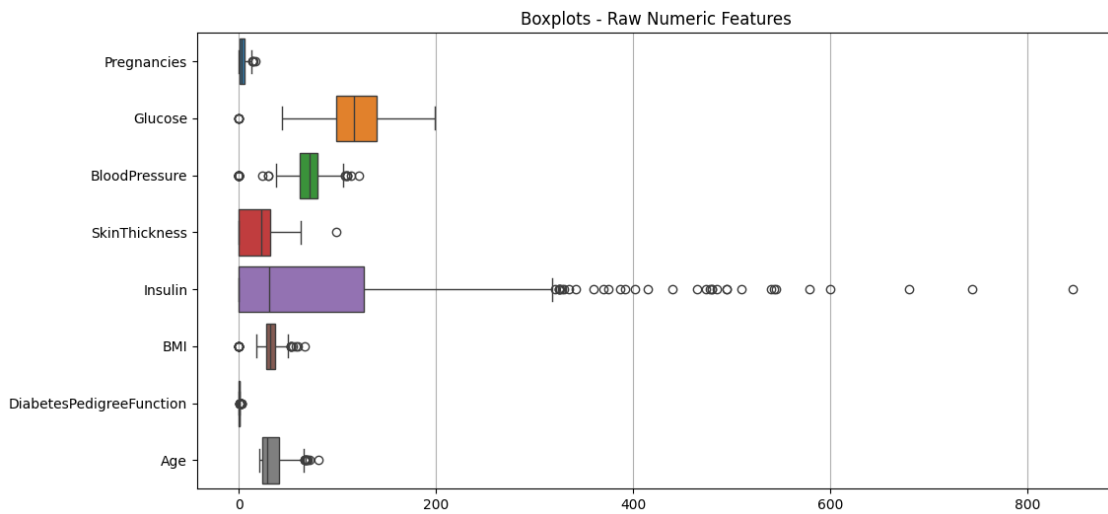
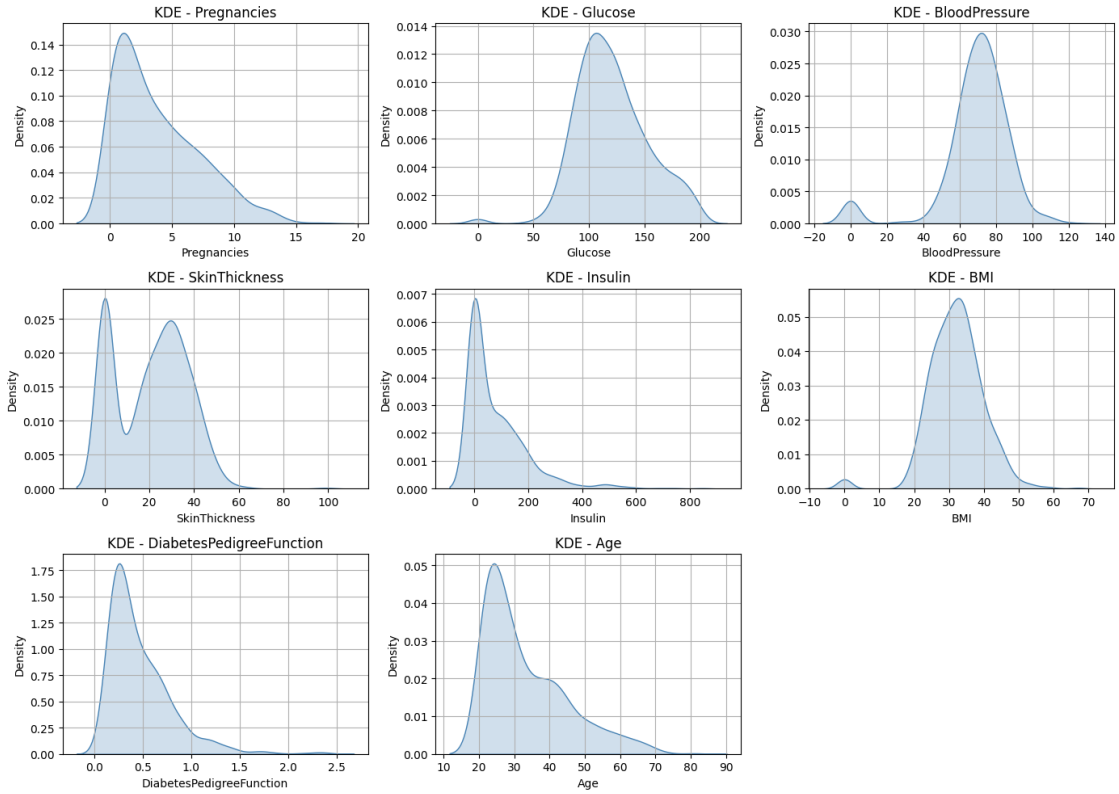
- Histogram, KDE, Boxplot để phát hiện outliers.


```
[8]: # Univariate plots
num_cols = [c for c in df.columns if c != 'Outcome']
# Histograms
_ = df[num_cols].hist(bins=30, figsize=(14,8))
plt.tight_layout()
plt.show()

# KDE plots
fig, axes = plt.subplots(len(num_cols)//3 + 1, 3, figsize=(14,10))
axes = axes.flatten()
for i,c in enumerate(num_cols):
    sns.kdeplot(df[c], ax=axes[i], fill=True, color='steelblue')
    axes[i].set_title(f'KDE - {c}')
for j in range(i+1, len(axes)):
    axes[j].axis('off')
plt.tight_layout()
plt.show()

# Boxplots
plt.figure(figsize=(12,6))
sns.boxplot(data=df[num_cols], orient='h')
plt.title('Boxplots - Raw Numeric Features')
plt.show()
```





1.10 11. Hiển thị đa biến (Multivariate Plots)

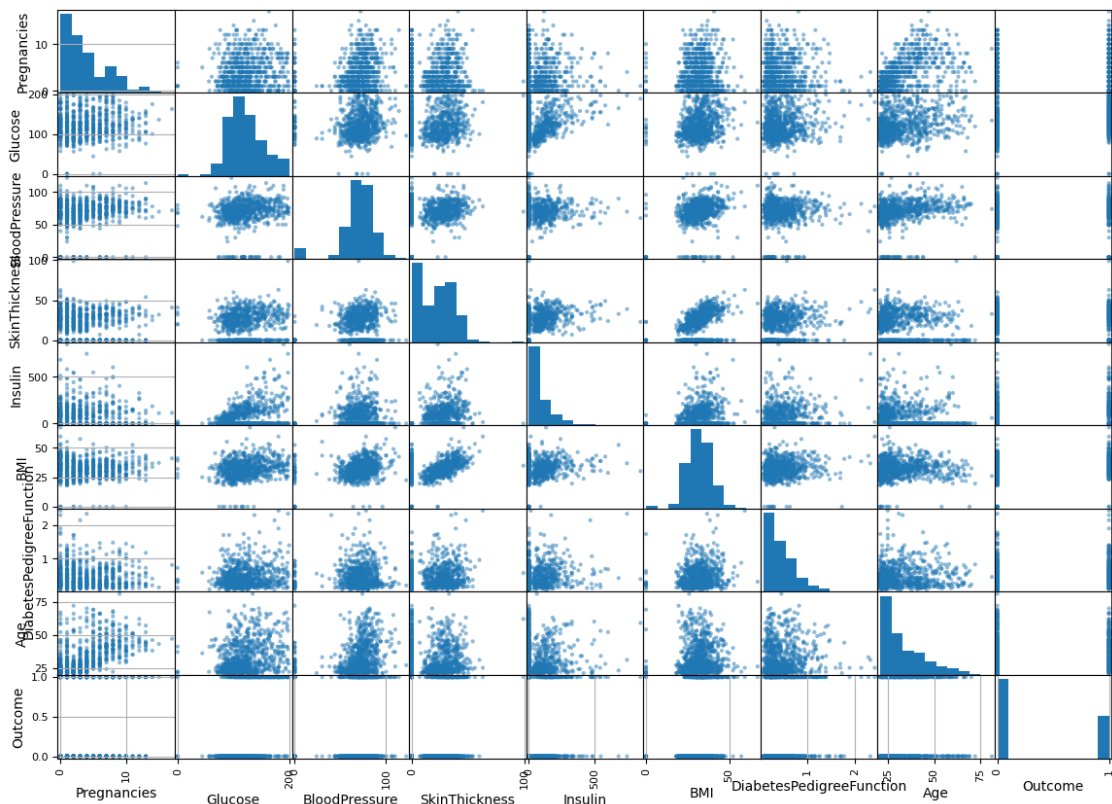
- Scatter matrix, pairplot, heatmap.


```
[9]: # Multivariate plots
# Scatter matrix (may be large)
pd.plotting.scatter_matrix(df[num_cols + ['Outcome']], figsize=(14,10),
    ↪diagonal='hist')
plt.suptitle('Scatter Matrix', y=1.02)
plt.show()

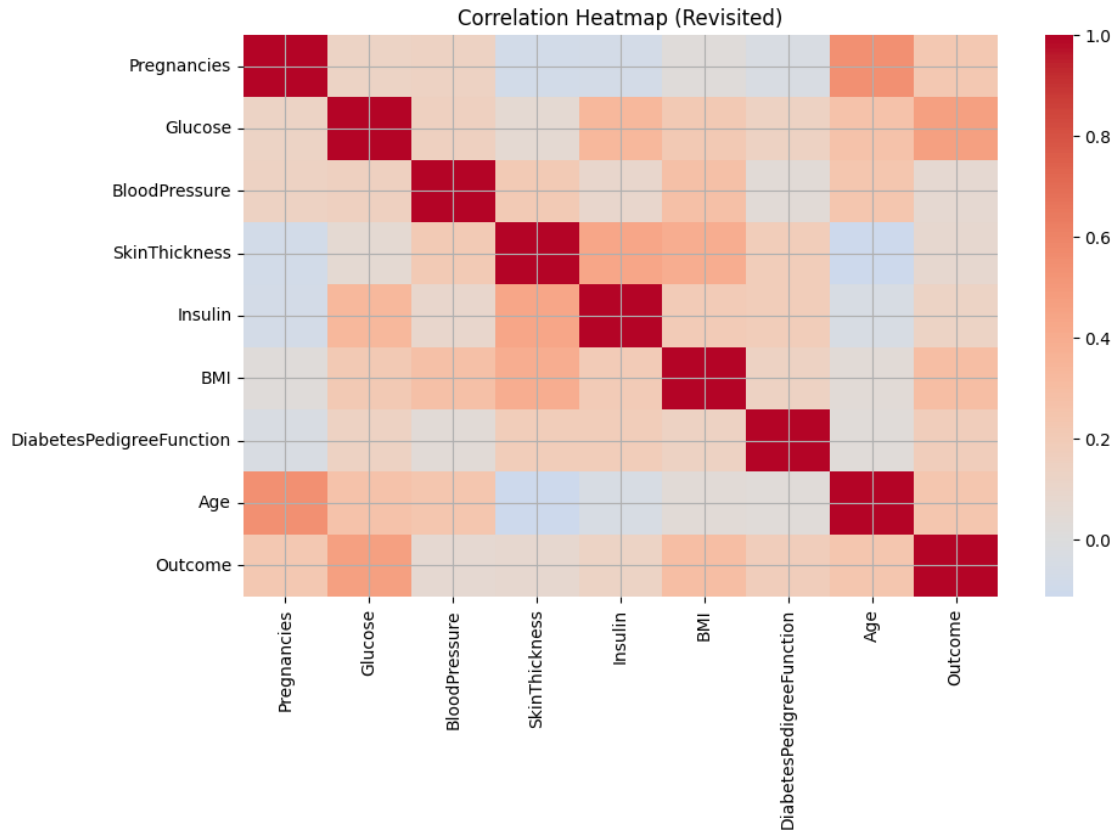
# Pairplot (sample if needed)
sample_df = df.sample(min(300, len(df)), random_state=42)
sns.pairplot(sample_df, hue='Outcome', diag_kind='hist', corner=True)
plt.show()

# Heatmap again (focused)
plt.figure(figsize=(10,6))
sns.heatmap(corr, cmap='coolwarm', annot=False, center=0)
plt.title('Correlation Heatmap (Revisited)')
plt.show()
```

Scatter Matrix







1.11 12. Tạo bản sao làm sạch (Create Clean DataFrame)

- Sao chép dữ liệu gốc để xử lý: `df_clean = df.copy()`

```
[10]: # Create clean copy
df_clean = df.copy()
print('Clean copy created. Shape:', df_clean.shape)
```

Clean copy created. Shape: (768, 9)

1.12 13. Xử lý giá trị 0 -> NaN rồi nội suy (Impute Missing Values)

- Thay giá trị 0 ở các cột sinh học bằng NaN rồi dùng median để điền.

```
[11]: # Impute zeros -> NaN -> median
impute_cols = ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI']
for c in impute_cols:
    zero_mask = df_clean[c] == 0
    n_zero = int(zero_mask.sum())
    if n_zero > 0:
        df_clean.loc[zero_mask, c] = np.nan
```

```

        median_val = df_clean[c].median()
        df_clean[c].fillna(median_val, inplace=True)
        print(f'{c}: replaced {n_zero} zeros with median={median_val:.2f}')

print('\nRemaining NaNs after imputation:')
print(df_clean[impute_cols].isna().sum())

```

Glucose: replaced 5 zeros with median=117.00
 BloodPressure: replaced 35 zeros with median=72.00
 SkinThickness: replaced 227 zeros with median=29.00
 Insulin: replaced 374 zeros with median=125.00
 BMI: replaced 11 zeros with median=32.30

Remaining NaNs after imputation:

Glucose	0
BloodPressure	0
SkinThickness	0
Insulin	0
BMI	0
dtype:	int64

1.13 14. Loại bỏ trùng lặp (Remove Duplicates)

```

[12]: # Remove duplicates
before = len(df_clean)
dup_n = df_clean.duplicated().sum()
print(f'Duplicated rows: {dup_n}')
if dup_n>0:
    df_clean.drop_duplicates(ignore_index=True, inplace=True)
    print(f'Removed {dup_n} duplicates. New shape: {df_clean.shape}')
else:
    print('No duplicates removed.')

```

Duplicated rows: 0
 No duplicates removed.

1.14 15. Mã hóa nhãn Output (Ensure Label Encoding)

- Outcome đã là 0/1; ép kiểu int và xác nhận.

```

[13]: # Ensure label encoding
df_clean['Outcome'] = df_clean['Outcome'].astype(int)
print('Unique Outcome values:', np.unique(df_clean['Outcome']))

```

Unique Outcome values: [0 1]

1.15 16. Chuẩn hóa dữ liệu Min-Max (MinMax Scaling)

- $z = (x - \min) / (\max - \min)$

```
[14]: # MinMax Scaling
scale_cols = [c for c in df_clean.columns if c != 'Outcome']
minmax_scaler = MinMaxScaler()
minmax_arr = minmax_scaler.fit_transform(df_clean[scale_cols])
df_minmax = df_clean.copy()
df_minmax[scale_cols] = minmax_arr
print('MinMax scaled. Range per column:')
for i,c in enumerate(scale_cols):
    print(c, f'min={df_minmax[c].min():.3f} max={df_minmax[c].max():.3f}')
```

```
MinMax scaled. Range per column:
Pregnancies min=0.000 max=1.000
Glucose min=0.000 max=1.000
BloodPressure min=0.000 max=1.000
SkinThickness min=0.000 max=1.000
Insulin min=0.000 max=1.000
BMI min=0.000 max=1.000
DiabetesPedigreeFunction min=0.000 max=1.000
Age min=0.000 max=1.000
```

1.16 17. Chuẩn hóa dữ liệu Standard (Standard Scaling)

- $z = (x - \mu) / \sigma$

```
[15]: # Standard Scaling
standard_scaler = StandardScaler()
standard_arr = standard_scaler.fit_transform(df_clean[scale_cols])
df_standard = df_clean.copy()
df_standard[scale_cols] = standard_arr
print('Standard scaled. Mean/std per column:')
for c in scale_cols:
    print(c, f'mean={df_standard[c].mean():.3f} std={df_standard[c].std():.3f}')
```


```
Standard scaled. Mean/std per column:
Pregnancies mean=-0.000 std=1.001
Glucose mean=0.000 std=1.001
BloodPressure mean=0.000 std=1.001
SkinThickness mean=-0.000 std=1.001
Insulin mean=0.000 std=1.001
BMI mean=0.000 std=1.001
DiabetesPedigreeFunction mean=0.000 std=1.001
Age mean=0.000 std=1.001
```

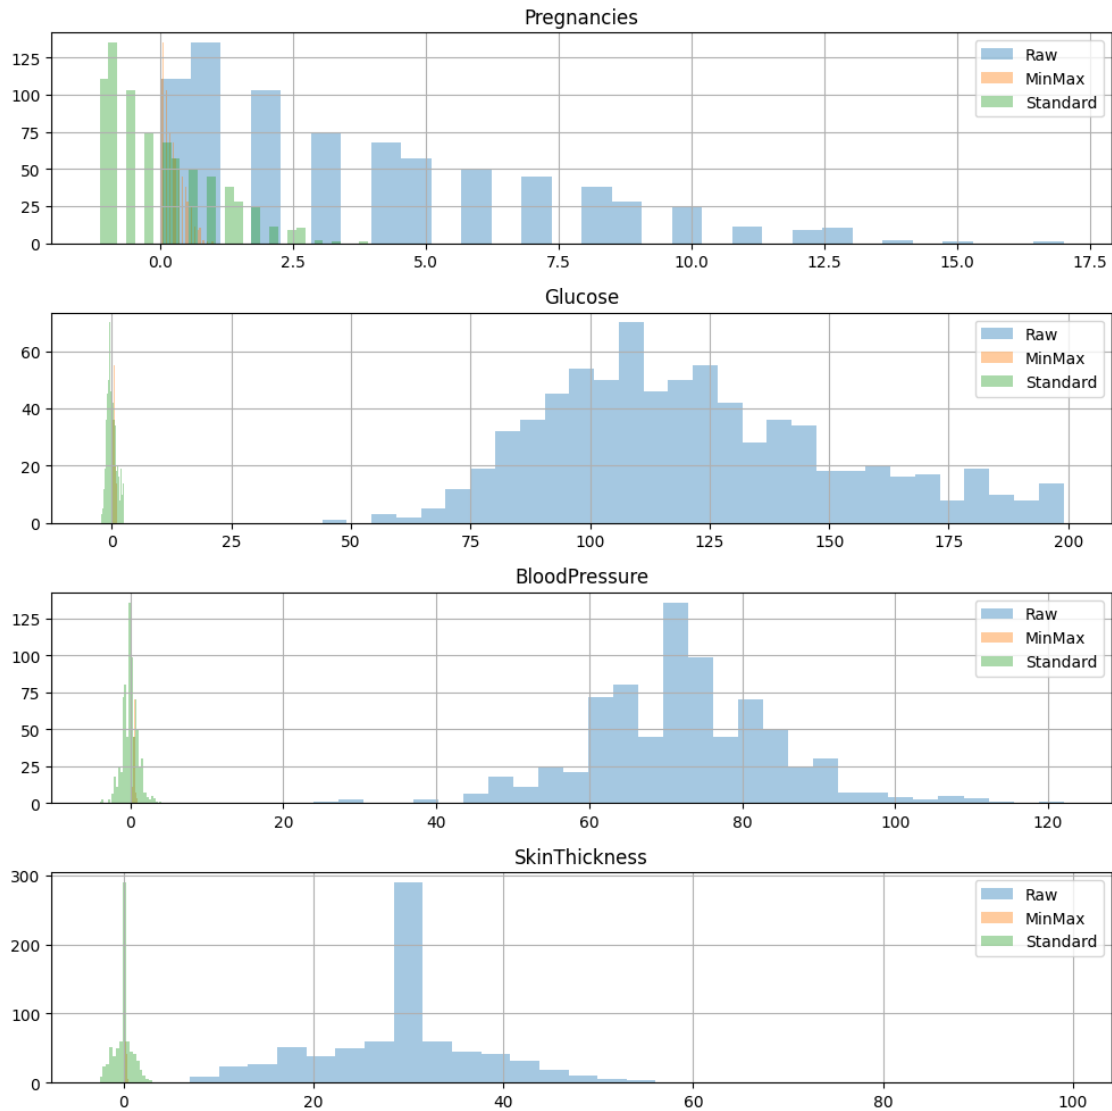
1.17 18. So sánh phân phối sau chuẩn hóa (Compare Scaled Distributions)

- Boxplot và histogram so sánh Raw vs MinMax vs Standard.

```
[16]: # Compare distributions
fig, axes = plt.subplots(3,1, figsize=(12,14))
sns.boxplot(data=df_clean[scale_cols], ax=axes[0], orient='h')
axes[0].set_title('Raw')
sns.boxplot(data=df_minmax[scale_cols], ax=axes[1], orient='h')
axes[1].set_title('MinMax')
sns.boxplot(data=df_standard[scale_cols], ax=axes[2], orient='h')
axes[2].set_title('Standard')
plt.tight_layout()
plt.show()

# Overlay hist for a few selected features
sel = scale_cols[:4]
fig, axes = plt.subplots(len(sel), 1, figsize=(10, 10))
for i,c in enumerate(sel):
    axes[i].hist(df_clean[c], bins=30, alpha=0.4, label='Raw')
    axes[i].hist(df_minmax[c], bins=30, alpha=0.4, label='MinMax')
    axes[i].hist(df_standard[c], bins=30, alpha=0.4, label='Standard')
    axes[i].set_title(c)
    axes[i].legend()
plt.tight_layout()
plt.show()
```



1.18 19. Tạo đặc trưng mới (Feature Engineering Optional)

- Ví dụ tạo nhóm tuổi, nhóm BMI, tương tác Glucose*BMI.

```
[17]: # Feature engineering (optional)
df_fe = df_clean.copy()
# Age group
age_bins = [0,30,40,50,60,100]
age_labels = ['<30', '30-39', '40-49', '50-59', '60+']
df_fe['AgeGroup'] = pd.cut(df_fe['Age'], bins=age_bins, labels=age_labels,
    ↪right=False)
# BMI category
bmi_bins = [0,18.5,25,30,100]
```

```

bmi_labels = ['Under', 'Normal', 'Over', 'Obese']
df_fe['BMICat'] = pd.cut(df_fe['BMI'], bins=bmi_bins, labels=bmi_labels,
    ↳right=False)
# Interaction
df_fe['Glucose_BMI'] = df_fe['Glucose'] * df_fe['BMI']
print('New columns added: AgeGroup, BMICat, Glucose_BMI')
display.
    ↳display(df_fe[['Age', 'AgeGroup', 'BMI', 'BMICat', 'Glucose', 'Glucose_BMI']])
    ↳head())
new_features = ['AgeGroup', 'BMICat', 'Glucose_BMI']

```

New columns added: AgeGroup, BMICat, Glucose_BMI

	Age	AgeGroup	BMI	BMICat	Glucose	Glucose_BMI
0	50	50-59	33.6	Obese	148.0	4972.8
1	31	30-39	26.6	Over	85.0	2261.0
2	32	30-39	23.3	Normal	183.0	4263.9
3	21	<30	28.1	Over	89.0	2500.9
4	33	30-39	43.1	Obese	137.0	5904.7

1.19 20. Tách Input/Output & ép kiểu (Split X / y)

- X_data, y_data.

```

[18]: # Split X/y
X_data = df_clean.drop('Outcome', axis=1).values
y_data = df_clean['Outcome'].values.astype(int)
print('Shapes:', X_data.shape, y_data.shape)
print('First 5 rows X:\n', X_data[:5])
print('First 20 y:', y_data[:20])

```

Shapes: (768, 8) (768,)

First 5 rows X:

```

[[6.000e+00 1.480e+02 7.200e+01 3.500e+01 1.250e+02 3.360e+01 6.270e-01
 5.000e+01]
[1.000e+00 8.500e+01 6.600e+01 2.900e+01 1.250e+02 2.660e+01 3.510e-01
 3.100e+01]
[8.000e+00 1.830e+02 6.400e+01 2.900e+01 1.250e+02 2.330e+01 6.720e-01
 3.200e+01]
[1.000e+00 8.900e+01 6.600e+01 2.300e+01 9.400e+01 2.810e+01 1.670e-01
 2.100e+01]
[0.000e+00 1.370e+02 4.000e+01 3.500e+01 1.680e+02 4.310e+01 2.288e+00
 3.300e+01]]

```

First 20 y: [1 0 1 0 1 0 1 0 1 1 0 1 0 1 1 1 1 0 1]

1.20 21. Chia tập Train/Test (Train/Test Split)

- Stratify theo Outcome, test_size=0.3, random_state=42.

```
[19]: # Train/Test split
X_train, X_test, y_train, y_test = train_test_split(
    X_data, y_data, test_size=0.3, stratify=y_data, random_state=42
)
print(f'Train size: {X_train.shape}, Test size: {X_test.shape}')
print('Train class distribution:', np.bincount(y_train))
print('Test class distribution:', np.bincount(y_test))
```

```
Train size: (537, 8), Test size: (231, 8)
Train class distribution: [350 187]
Test class distribution: [150  81]
```

1.21 22. Lưu dữ liệu & đối tượng tiền xử lý (Persist Artifacts)

- Lưu: data.npz, df_clean.csv, scaler objects.
- Thư mục: exps/diabetes

```
[20]: # Persist artifacts
save_dir = 'exps/diabetes'
os.makedirs(save_dir, exist_ok=True)

# Save numpy data
np.savez(f'{save_dir}/data.npz', X_train=X_train, X_test=X_test,
        y_train=y_train, y_test=y_test)
# Save cleaned dataframe
clean_path = f'{save_dir}/df_clean.csv'
df_clean.to_csv(clean_path, index=False)
# Save scalers
joblib.dump(minmax_scaler, f'{save_dir}/minmax_scaler.joblib')
joblib.dump(standard_scaler, f'{save_dir}/standard_scaler.joblib')

print('Saved files:')
print(os.listdir(save_dir))
```

```
Saved files:
['data.npz', 'df_clean.csv', 'standard_scaler.joblib', 'minmax_scaler.joblib']
```

2 Kết thúc

```
[24]: !jupyter nbconvert diabetes_analysis.ipynb --to latex
```

```
[NbConvertApp] Converting notebook diabetes_analysis.ipynb to latex
[NbConvertApp] ERROR | Error while converting 'diabetes_analysis.ipynb'
Traceback (most recent call last):
  File "/home/tp_ubuntu/colab/.venv/lib/python3.12/site-
packages/nbconvert/nbconvertapp.py", line 487, in export_single_notebook
    output, resources = self.exporter.from_filename(
                        ^^^^^^^^^^^^^^^^^^^^^^^^^^
```

[illegible]

